

HAR

15,63M
μετρήσεις

51 άτομα • 18
δραστηριότητες

PySpark MLlib
Google Cloud

Κατανεμημένη Αναγνώριση Ανθρώπινης Δραστηριότητας

HAR: αναγνώριση δραστηριότητας από κινήσεις που καταγράφουν κινητό και έξυπνο ρολόι.

WISDM: δημόσιο σύνολο δεδομένων 51 ατόμων και 18 δραστηριοτήτων.

Σύγκριση Λογιστικής Παλινδρόμησης και Random Forest με PySpark στο Google Cloud.

Κωστας Φύκατας

Ακαδημαϊκό έτος 2025-2026

- Φορετές συσκευές και τηλέφωνα παράγουν συνεχείς, πολυδιάστατες χρονοσειρές.
- Η HAR υποστηρίζει υγεία, άθληση, υποβοηθούμενη διαβίωση και ασφάλεια.
- Εκτός από την ορθότητα πρόβλεψης, εξετάζεται η κατανεμημένη επεξεργασία στο νέφος.

RQ1

Ποιο μοντέλο γενικεύει σε νέα άτομα;

RQ2

Συσκευή, αισθητήρες και μέγεθος παραθύρου;

RQ3

Κοινός κώδικας τοπικά και στο νέφος;

RQ4

Ποιότητα έναντι χρόνου/κόστους;

Στόχος

Πλήρης ροή • χωρίς διαρροή • αναπαραγωγή • εκτέλεση στο νέφος

WISDM: δεδομένα κινητού και έξυπνου ρολογιού

03

15,63 M

μετρήσεις
αισθητήρων

51

άτομα

18

δραστηριότητες

20 Hz

ρυθμός
δειγματοληψίας

CC BY 4.0

DOI
10.24432/C5HK59

15.630.426 μετρήσεις ανθρώπων κατά την εκτέλεση γνωστών δραστηριοτήτων. 20 Hz = 20 μετρήσεις ανά δευτερόλεπτο.

4 ροές αισθητήρων

ΚΙΝΗΤΟ

επιταχυνσιόμετρο

ΚΙΝΗΤΟ

γυροσκόπιο

ΡΟΛΟΪ

επιταχυνσιόμετρο


ΡΟΛΟΪ

γυροσκόπιο

18 κλάσεις — βάδισμα, τρέξιμο, πληκτρολόγηση, φαγητό, γράψιμο, δίπλωμα ρούχων κ.ά.

Από τις μετρήσεις στα χαρακτηριστικά με Spark

04



Παράθυρο: ομάδα μετρήσεων από 5 ή 10 s

Χαρακτηριστικό: αριθμός που συνοψίζει την κίνηση

- μέσος, τυπική απόκλιση, ελάχιστο, μέγιστο για $x / y / z$
- μέσος και τυπική απόκλιση μέτρου, μέση ενέργεια
- $\text{corr}(x,y)$, $\text{corr}(x,z)$, $\text{corr}(y,z)$
- ≥ 150 μετρήσεις στο κύριο παράθυρο 10 s

$$m = \sqrt{x^2 + y^2 + z^2}$$

$$\text{window_id} = \lfloor \text{timestamp} / T_v \rfloor$$

Συνένωση: 18 επιταχ. + 18 γυροσκοπίου = 36 τιμές ανά παράθυρο

Πρόβλημα τυχαίου διαχωρισμού παραθύρων

Καταγραφές του ίδιου ατόμου σε
εκπαίδευση και δοκιμή → διαρροή
προσωπικών μοτίβων → υπερεκτίμηση
επίδοσης.

Επιλεγμένη μέθοδος

Διαχωρισμός με SHA-256 → δεδομένα
35 / 8 / 8 ατόμων. Οι καταγραφές των
8 ατόμων της δοκιμής δεν
χρησιμοποιούνται στην εκπαίδευση.

35 άτομα

ΕΚΠΑΙΔΕΥΣΗ μοντέλου

8 άτομα

ΕΠΙΚΥΡΩΣΗ • χωρίς
αναζήτηση παραμέτρων

8 άτομα

ΔΟΚΙΜΗ • τελική αξιολόγηση

Όλες οι καταγραφές ενός ατόμου στο ίδιο σύνολο • seed = 42

Δύο MLlib μέθοδοι — τέσσερις συνθήκες

06

Πολυταξική Λογιστική Παλινδρόμηση

γραμμικό μοντέλο αναφοράς • πιθανότητα ανά δραστηριότητα • maxIter=80 • L2=0.05

Random Forest

Συνδυάζει πιθανότητες από 80 δέντρα • depth=12 • sqrt

1 Κινητό: επιταχυνσιόμετρο

παράθυρο 5 s

2 Κινητό: δύο αισθητήρες

παράθυρο 5 s

3 Κινητό: δύο αισθητήρες

παράθυρο 10 s

4 Ρολόι: δύο αισθητήρες

παράθυρο 10 s

Δείκτες ορθότητα • macro-F1 • ακρίβεια/ανάκληση • πίνακας σύγχυσης • χρόνοι

Εκπαίδευση Λογιστικής Παλινδρόμησης

07



$$p(y=1|x) = 1 / (1 + e^{-(b_0 + b_1 x)})$$

Παράμετροι μοντέλου

- Η εκπαίδευση προσδιορίζει τους συντελεστές b_0 και b_1 .
- Οι συντελεστές μετακινούν και αλλάζουν την κλίση της καμπύλης.
- Στόχος: υψηλή πιθανότητα στη σωστή γνωστή δραστηριότητα.


Στο πραγματικό πείραμα

36 χαρακτηριστικά • 18 δραστηριότητες
Softmax: μετατρέπει τις 18 βαθμολογίες σε πιθανότητες με άθροισμα 100%.

Εκπαίδευση Random Forest

08


Κάθε κόμβος επιλέγει χαρακτηριστικό και αριθμητικό όριο.



Ενδεικτικά όρια τυποποιημένων χαρακτηριστικών, όχι μετρήσεις της εκτέλεσης. Τα φύλλα δείχνουν μόνο την επικρατέστερη κλάση.

Η εκπαίδευση επιλέγει το χαρακτηριστικό και το όριο που διαχωρίζουν καλύτερα τις δραστηριότητες.

80 διαφορετικά δέντρα



τυχαία δείγματα + διαφορετικά υποσύνολα χαρακτηριστικών

Παράδειγμα: 3 δέντρα, 2 δραστηριότητες

W 90%
J 10%

W 60%
J 40%

W 30%
J 70%

Μέσος όρος: W 60% • J 40%

**Μεγαλύτερη πιθανότητα →
ΒΑΔΙΣΜΑ**

W = βάδισμα • J = τρέξιμο

Κοινή ροή PySpark: τοπικά και στο Google Cloud

09

ΤΟΠΙΚΑ

ανάπτυξη και γρήγορες δοκιμές

- Debian + Python 3.11 + Java 17
- PySpark 3.5.3 • local[6]
- Χαρακτηριστικά Parquet • εκτελέσεις με χρονική σήμανση

GOOGLE CLOUD

διαχειριζόμενη κατανεμημένη εκτέλεση


- Ιδιωτικός χώρος Cloud Storage
- Διαχειριζόμενο Spark 2.3 LTS
- Λογαριασμός υπηρεσίας χωρίς αρχείο κλειδιού
- Εργασία νέφους • europe-west1



Serverless: προσωρινές διεργασίες Spark δημιουργούνται για την εργασία και τερματίζονται μετά.

Αποτελέσματα: υπεροχή του Random Forest

10



62,14%

μέγιστη ορθότητα δοκιμής

61,90%


μέγιστο macro-F1

**Ρολόι, δύο αισθητήρες, 10 s
Random Forest**

Ορθότητα = ποσοστό σωστών προβλέψεων

F1 = ισορροπία ακρίβειας και ανάκλησης

Macro-F1 = μέσο F1 των 18 δραστηριοτήτων • τυχαία επιλογή $\approx 5,56\%$



Ευρήματα

- Γυροσκόπιο: μικρή αλλά σταθερή βελτίωση στο τηλέφωνο.
- Παράθυρο 10 s: μικρή βελτίωση έναντι 5 s.
- Ρολόι: μεγαλύτερη μεταβολή· πολλές κλάσεις αφορούν κινήσεις χεριού.
- Random Forest: +13,42 μονάδες macro-F1 στο κύριο πείραμα.

F1


Συνδυάζει ακρίβεια και ανάκληση:
ορθές προβλέψεις και εντοπισμό παραδειγμάτων.

Macro-F1: μέσο F1, με ίδιο βάρος και στις 18 δραστηριότητες.


Ανάλυση σφαλμάτων του καλύτερου μοντέλου

12

Αριστερά: πραγματική δραστηριότητα × πρόβλεψη — η σκούρα διαγώνιος είναι σωστή πρόβλεψη.




Δεξιά: F1 ανά δραστηριότητα· μεγαλύτερη ράβδος δηλώνει καλύτερη ισορροπία ακρίβειας και ανάκλησης.



Η σύγχυση παρόμοιων λεπτών κινήσεων καθιστά αναγκαίο το macro-F1, πέρα από την ορθότητα.

Χρόνος εκτέλεσης και αναπαραγωγισιμότητα

13



SUCCEEDED

κατάσταση εργασίας
νέφους

44m 47s

διάρκεια στο νέφος

13.38 DCU-h

υπολογιστική χρήση — όχι τιμή σε ευρώ

Αναπαραγωγισιμότητα

SHA-256 • YAML • σταθερός διαχωρισμός • δοκιμές •
Parquet • μοντέλα • αποτελέσματα JSON

DCU-h = συνολική χρήση πόρων Spark. Τα 44m 47s περιλαμβάνουν
διάθεση πόρων, προεπεξεργασία, εκπαίδευση και αποθήκευση.

batch: har-watch-10s-20260827-055742

62,14%

RF • ρολόι, δύο αισθητήρες • 10 s

35 / 8 / 8

δεδομένα ανά άτομο

Τοπικά + Νέφος

κοινή ροή PySpark

ΟΡΙΑ

Το 62% υπερβαίνει σαφώς την τυχαία επιλογή, αλλά δεν αρκεί για ιατρική χρήση ή εφαρμογές κρίσιμης ασφάλειας.

Παραδοτέα: κώδικας • δοκιμές • ρυθμίσεις • αποτελέσματα • μοντέλα • αναφορά • διαφάνειες

Μελλοντική εργασία: FFT / επικαλυπτόμενα παράθυρα / μοντέλο αναφοράς CNN-LSTM